次フレーム予測からの学習：統一的かつスケーラブルな視覚表現学習に向けて

Original Title: Learning from Next-Frame Prediction: Towards Unified and Scalable Visual Representation Learning

一言要約: 次フレーム予測で視覚の本質を捉える新手法

著者	Y Yao, J Li, Z Zhang, Y Xiong, Y Jin, K Xu, H Zhang
掲載誌	arXiv preprint arXiv 2026
キーワード	representation learning
PDF	https://arxiv.org/pdf/2610.30724
原文リンク	https://scholar.google.com/scholar_url?url=https://arxiv.org/pdf/2610.30724&hl=ja&sa=X&d=9010873826006731788&ei=AuLdas6qDMimieoP4sreqQc&scisig=ACTRDVGfsYq4vNx7syrdClGKu9gU&oi=scholaralrt&hist=RO4okA8AAAAJ:15402290568201949701:ACTRDVEUaj6DyP4NO0AosE8K3gN9&html=&pos=0&folt=kw-top

■ 新規性の図解（先行研究との違いと本研究のブレークスルー）

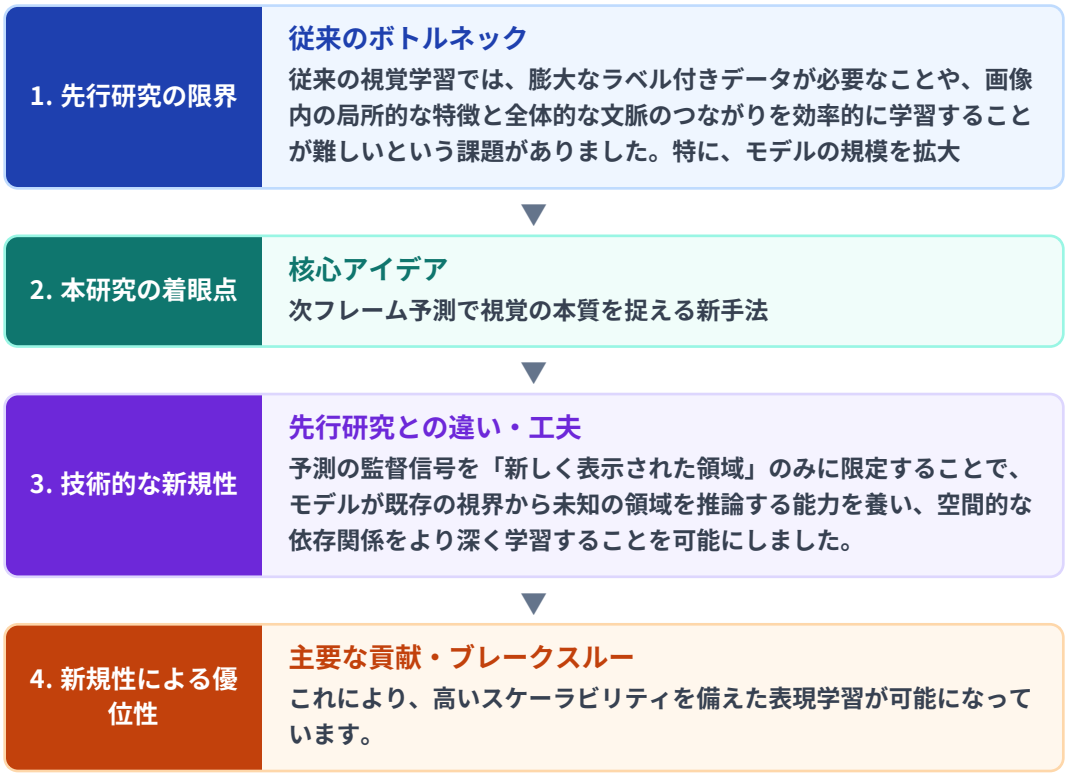

■ 要約

映像や画像の次の展開を予測するタスクを通じて、汎用的な視覚的特徴を学習する新しい手法を提案しています。画像を局所から広域へと順次提示し、新しく現れる領域を予測させることで、文脈を理解するスケーラブルな学習を実現しました。

■ どんな問題に取り組んだか

従来の視覚学習では、膨大なラベル付きデータが必要なことや、画像内の局所的な特徴と全体的な文脈のつながりを効率的に学習することが難しいという課題がありました。特に、モデルの規模を拡大した際に性能が飽和せず、効率的に学習を続けられる統一的な手法が求められていました。

■ 何が新しい？何がすごい？（新規性）

本研究の革新性は、動画の次フレーム予測の概念を静止画の視覚表現学習に応用し、画像を「局所から広域へ」と段階的に展開するクロップ順序を導入した点にあります。予測の監督信号を「新しく表示された領域」のみに限定することで、モデルが既存の視界から未知の領域を推論する能力を養い、空間的な依存関係をより深く学習することを可能にしました。これにより、高いスケーラビリティを備えた表現学習が可能になっています。

■ 大学1年生向けの解説

パズルのピースを少しずつ見せて「次にどんな絵が出てくるか」をAIに予想させる学習方法です。最初はズームした小さな範囲から始め、徐々にカメラを引きながら広い範囲を見せることで、AIは物体の形だけでなく、周囲との関係性も理解できるようになります。この方法を使うと、人間が正解ラベルを教えなくても、AIは大量のデータから勝手に物の見方を効率よく学んでいくことができます。